



南京理工大学
NANJING UNIVERSITY OF SCIENCE & TECHNOLOGY

感知机 (Perceptron)

程煦

xcheng8@njust.edu.cn

计算机科学与工程学院



Outline


- 感知机模型
- 感知机学习策略
- 感知机学习算法
- 多层感知机与神经网络

感知机：提出背景




- 1958年由Frank Rosenblatt在康奈尔航空实验室提出，这是最早的人工神经网络模型之一，被认为是现代神经网络的起点，为后来的深度学习奠定了基础。
- 早期模式识别需求：当时的计算机主要用于数值计算，而科学家希望机器能像人类一样识别图片、字符、声音等模式。
- 神经科学的启发，感知机模型基于神经元的工作原理，模拟大脑神经元的输入、加权求和、激活函数等计算方式
- 感知机是一种线性分类器。

感知机基于神经元的工作原理



- 神经元（Neuron）是大脑的基本计算单元，由树突（Dendrites）、胞体（Soma）、轴突（Axon）组成
- 树突接收其他神经元的信号，并将其传输到胞体。
- 当输入信号的总和超过某个**阈值**时，神经元会被激活，并通过**轴突**向下一个神经元传递信号。

感知机基于神经元的工作原理




感知机是一个简单的线性分类器，核心思想是：

- 1.输入信号（对应神经元的树突接收信号）。
- 2.加权求和（对应神经元对输入信号进行加权累加）。
- 3.激活函数（对应神经元超过阈值时被激活）。
- 4.输出结果（对应神经元向下游神经元传递信号）。


感知机模型

- 是一种线性分类模型，用于解决线性可分的二分类问题
 - 在二维就是找到一条直线，在三维或者更高维就是找到一个超平面，将两个类别的数据分开。
 - 找不到这条直线或超平面就是类别线性不可分，感知机不适合该数据分类。使用感知机最大前提就是数据线性可分。



感知机模型

- 是一种线性分类模型，用于解决线性可分的二分类问题



核心思想是：


1. 输入信号（对应神经元的树突接收信号）。
2. 加权求和（对应神经元对输入信号进行加权累加）。



- 输入特征：给定输入数据 \mathbf{x} 以及权重 \mathbf{w} ，计算加权求和 $\mathbf{w}^T \mathbf{x} + b$, $\mathbf{x}^T = [x_1, x_2, \dots, x_d]$, $\mathbf{w}^T = [w_1, w_2, w_3, \dots, w_d]$

感知机模型

- 是一种线性分类模型，用于解决线性可分的二分类问题



3. 激活函数（对应神经元超过阈值时被激活）。


4. 输出结果（对应神经元向下游神经元传递信号）。



- 激活函数：使用阶跃函数 $\text{sign}()$ 将加权求和结果转换为 -1 或 1，实现二分类 $\hat{y} = \text{sign}(\mathbf{w}^T \mathbf{x} + b)$ 。

感知机模型

- 激活函数：使用阶跃函数 $\text{sign}()$ 将加权求和结果转换为 -1 或 1，实现二分类 $\hat{y} = \text{sign}(\mathbf{w}^T \mathbf{x} + b)$ 。



即 $x > 0, \text{sgn} x = 1 \rightarrow$ 分为正类

$x = 0, \text{sgn} x = 0 \rightarrow \mathbf{w}^T \mathbf{x} + b = 0$
是决策边界

$x < 0, \text{sgn} x = -1 \rightarrow$ 分为负类


感知机模型

- 是一种线性分类模型，用于解决线性可分的二分类问题

1. 输入特征：给定输入数据 \mathbf{x} 以及权重 \mathbf{w} ，计算加权求和

$$\mathbf{w}^T \mathbf{x} + b, \mathbf{x}^T = [x_1, x_2, \dots, x_d], \mathbf{w}^T = [w_1, w_2, w_3, \dots, w_d]$$

2. 激活函数：使用阶跃函数 $\text{sign}()$ 将加权求和结果转换为 -1 或 1，实现二分类 $\hat{y} = \text{sign}(\mathbf{w}^T \mathbf{x} + b)$ 。



$$\hat{y} = \text{sign}(\mathbf{w}^T \mathbf{x} + b) = \begin{cases} 1, & \mathbf{w}^T \mathbf{x} + b > 0 \\ -1, & \mathbf{w}^T \mathbf{x} + b < 0 \end{cases}$$

感知机损失函数

- 感知机的目标是找到一个线性超平面将数据分类，即

$$\mathbf{w}^T \mathbf{x} + b = 0$$

- 因为：感知机对一个输入样本 \mathbf{x}_i 进行分类的决策规则是

$$\hat{y}_i = \text{sign}(\mathbf{w}^T \mathbf{x} + b)$$

- $\hat{y}_i = 1$ 表示被分类到正类，
 - $\hat{y}_i = -1$ 表示被分类到负类。
- $\mathbf{w}^T \mathbf{x} + b = 0$: 模型无法区分，数据点正好位于分类边界上
- 决策边界定义：使得模型预测发生变化的分界面，即使得 \hat{y}_i 由 +1 变为 -1 的点的集合。在感知机中，这些点满足 $\mathbf{w}^T \mathbf{x} + b = 0$

该方程描述了一个超平面：

- 在二维空间，它是一直线： $w_1x_1 + w_2x_2 + b = 0$
- 在三维空间，它是一个平面
- 在更高维空间，它是一个超平面

这个超平面将数据分为两类，不同类别的数据点落在超平面的两侧。因此，它是感知机的决策边界。

感知机损失函数

- 为了正确分类，理想情况下应该满足

$$y_i(\mathbf{w}^T \mathbf{x} + b) > 0$$

$y_i \in \{-1, 1\}$ 是样本真实类别标签。

- 损失函数：只对错误分类的样本 $y_i(\mathbf{w}^T \mathbf{x} + b) \leq 0$ 进行优化

■ 给定训练集： $\{(\mathbf{x}_i, y_i)\}$, $i \in \{1, 2, \dots, N\}$

$$\min_{\mathbf{w}} L(\mathbf{w}) = - \sum_{\mathbf{x}_i \in \mathcal{M}} y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

➤ \mathcal{M} 为分类错误样本的集合： $\mathcal{M} = \{\mathbf{x}_i | y_i(\mathbf{w}^T \mathbf{x} + b) \leq 0\}$

感知机损失函数

- 损失函数：只对错误分类的样本 $y_i(\mathbf{w}^T \mathbf{x} + b) \leq 0$ 进行优化

$$\min_{\mathbf{w}, b} L(\mathbf{w}) = - \sum_{\mathbf{x}_i \in \mathcal{M}} y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

- **损失函数的 motivation:** 如果样本 \mathbf{x}_i 被误分类，意味着 $y_i(\mathbf{w}^T \mathbf{x}_i + b) \leq 0$ 。直觉上，我们希望增大 $y_i(\mathbf{w}^T \mathbf{x}_i + b)$ ，使其变为正数，即调整 \mathbf{w} 使得误分类样本向正确的决策边界靠近。
- **损失函数的物理意义:** 如果 $y_i(\mathbf{w}^T \mathbf{x}_i + b)$ 是负的，那么损失 $L(\mathbf{w})$ 会较大。目标是让损失变小，即让所有 $y_i(\mathbf{w}^T \mathbf{x}_i + b)$ 都变为正值。

感知机损失函数

- 损失函数：只对错误分类的样本 $y_i(\mathbf{w}^T \mathbf{x} + b) \leq 0$ 进行优化

$$\min_{\mathbf{w}, b} L(\mathbf{w}) = - \sum_{\mathbf{x}_i \in \mathcal{M}} y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

→
$$\min_{\mathbf{w}, b} L(\mathbf{w}) = \sum_{i=1}^N \max(0, -y_i (\mathbf{w}^T \mathbf{x}_i + b))$$

- 若样本被正确分类（ $y_i(\mathbf{w}^T \mathbf{x}_i + b) > 0$ ），损失为 0
- 若样本被错误分类，损失为 $-y_i(\mathbf{w}^T \mathbf{x}_i + b)$

梯度下降更新感知机参数

- 目标: $\min_{\mathbf{w}, b} L(\mathbf{w}) = \sum_{i=1}^N \max(0, -y_i (\mathbf{w}^T \mathbf{x}_i + b))$

- 梯度下降

- 若样本被错误分类, 损失为 $-y_i(\mathbf{w}^T \mathbf{x}_i + b)$

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} = - \sum_{\mathbf{x}_i \in \mathcal{M}} y_i \mathbf{x}_i$$

$$\frac{\partial L(\mathbf{w})}{\partial b} = - \sum_{\mathbf{x}_i \in \mathcal{M}} y_i$$

- 若样本被正确分类, 损失为0

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}} = 0 \qquad \frac{\partial L(\mathbf{w})}{\partial b} = 0$$

梯度下降更新感知机参数

- 目标: $\min_{\mathbf{w}, b} L(\mathbf{w}) = \sum_{i=1}^N \max(0, -y_i (\mathbf{w}^T \mathbf{x}_i + b))$

- 梯度下降

(1) 选取初值 w_0, b_0

(2) 在训练集中选取数据 (x_i, y_i)

(3) 如果 $y_i(w \cdot x_i + b) \leq 0$

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha y_i \mathbf{x}_i$$

$$b \leftarrow b + \alpha y_i$$

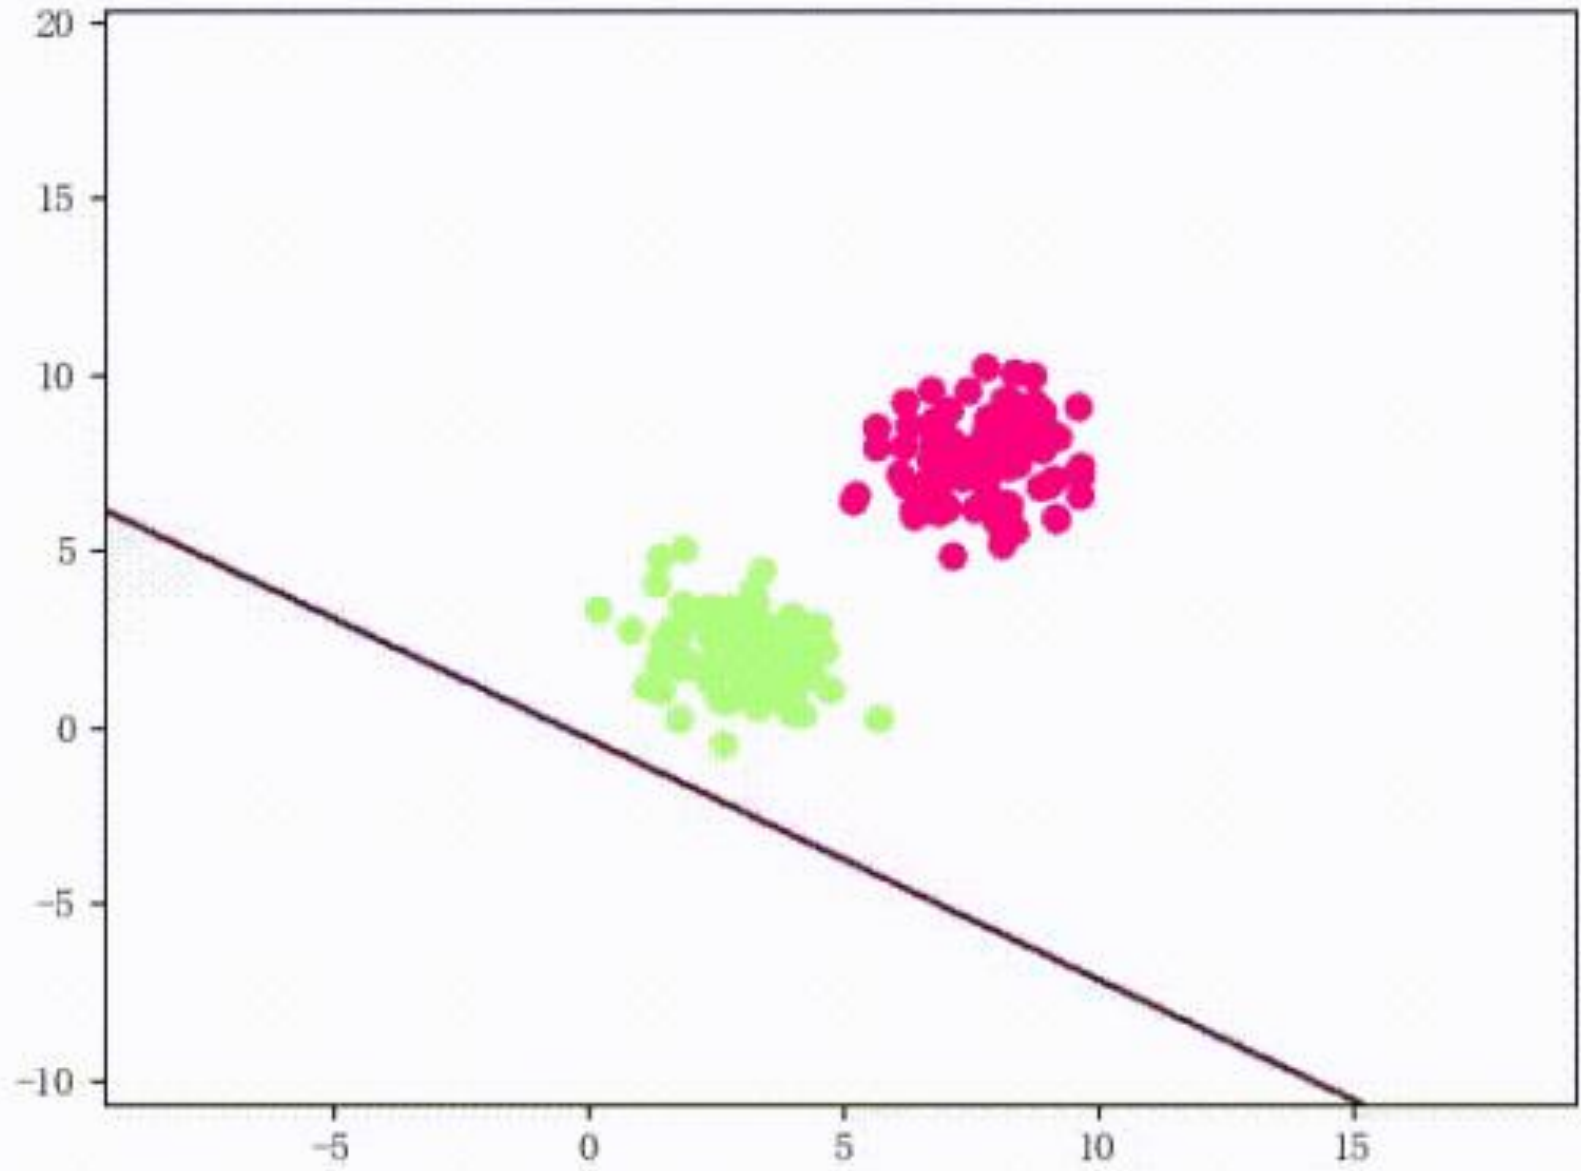
(4) 转至 (2), 直至训练集中没有误分类点

感知机模型的训练原理

- 基本原理就是逐点修正


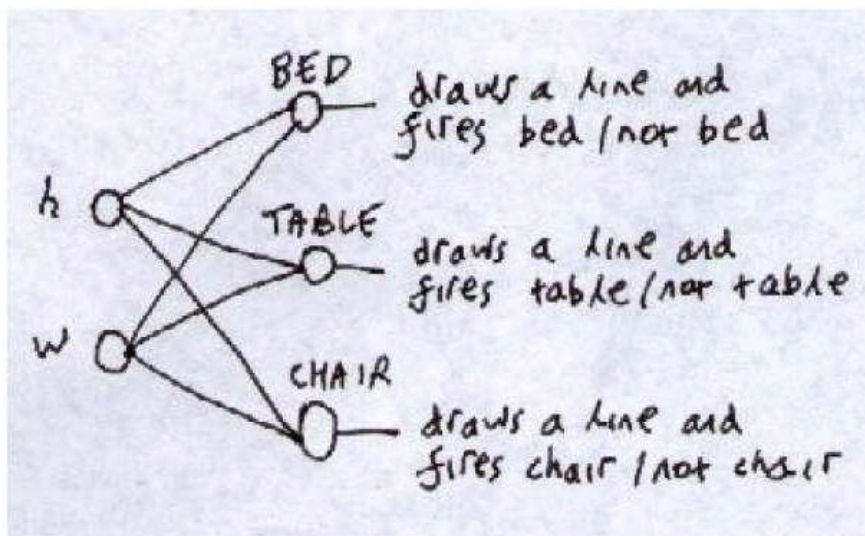
- （1）在超平面上随意取一个分类面，统计分类错误的点；
- （2）随机对某个错误点进行修正，即变换直线的位置（ \mathbf{w} 和 \mathbf{b} ），使该错误点得以修正；
- （3）再随机选择一个错误点进行纠正，分类面不断变化，直到所有的点都完全分类正确了，就得到了最佳的分类面。

感知机原理



多分类感知机

- 多类感知机是对感知机的扩展，用于解决多类分类问题。
- 广泛应用于图像分类中、自然语言处理（例如，在情感分析中可以应用多分类感知机将输入的文本映射到“正面”，“负面”和“中立”）等问题上。



多分类感知机模型

- **核心思想：**通过一对多方法（one-vs-rest）应用感知器模型

在一对多方法中，针对每个类别 j 训练一个二分类器，该分类器的任务是区分类别 j 和所有其他类别。也就是说，分类器的输出是：

- 对于类别 j : $y_j = 1$
- 对于其他类别 $k \neq j$: $y_k = -1$

假设有 C 个类别，则将训练 C 个感知机，每个感知机的目标是区分类别 j 和其他类别。最终的预测是通过选取预测概率最大的类别来确定。

- **多分类感知机模型：**

- 对于每个类别 j , 训练一个感知机去区分是类别 j vs 非类别 j

$$f_j = \text{sign}(\mathbf{w}_j^T \mathbf{x}_i + b_j)$$

多分类感知机模型

- 对于每个类别 j , 训练一个感知机区分是类别 j vs 非类别 j

$$f_j = \text{sign}(\mathbf{w}_j^T \mathbf{x}_i + b_j)$$

- 最终输出 C^* : 将样本分类到得分最大的类别上

$$C^* = \arg \max_{j=1, \dots, C} \mathbf{w}_j^T \mathbf{x}_i + b_j$$

- 损失函数: 对于每个样本 \mathbf{x}_i , 感知机的目标是尽量让正确类别 y_i 的得分最大, 同时让其他类别的得分较小。

$$\min L(\mathbf{w}) = \sum_{i=1}^N \sum_{j \neq y_i}^N \max(0, (\mathbf{w}_j^T \mathbf{x}_i + b_j) - (\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}))$$

多分类感知机模型

- 损失函数：对于每个样本 \mathbf{x}_i ，感知机的目标是尽量让正确类别 y_i 的得分最大，同时让其他类别的得分较小。

$$\min L(\mathbf{w}) = \sum_{i=1}^N \sum_{j \neq y_i}^N \max(0, (\mathbf{w}_j^T \mathbf{x}_i + b_j) - (\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}))$$

- ✓ $\max(0, \cdot)$ ：如果 $\mathbf{w}_j^T \mathbf{x}_i + b_j$ 大于正确类别 $\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}$ ，则会增加损失值，反之不增加损失。
- ✓ 最大化正确类别的得分：确保每个样本的正确类别得分大于其他类别的得分。
- ✓ 最小化误分类的得分差距：通过惩罚那些得分差距较小的错误分类，鼓励模型进行更准确的分类。

梯度下降更新多分类感知机模型

■ 优化目标

$$\min L(\mathbf{w}) = \sum_{i=1}^N \sum_{j \neq y_i}^N \max(0, (\mathbf{w}_j^T \mathbf{x}_i + b_j) - (\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}))$$

■ 计算梯度，对于 $\forall j \neq y_i$

$$\frac{\partial L(\mathbf{w})}{\partial \mathbf{w}_j} = \begin{cases} \mathbf{x}_i, & \text{if } (\mathbf{w}_j^T \mathbf{x}_i + b_j) - (\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}) > 0 \\ 0, & \text{otherwise} \end{cases}$$

具体来说，如果 $j \neq y_i$ 且 $\mathbf{w}_j^T \mathbf{x}_i + b_j - (\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}) > 0$ ，那么就更新权重 \mathbf{w}_j 使得 \mathbf{w}_j 更接近样本 \mathbf{x}_i 以减少损失。

梯度下降更新多分类感知机模型

- 优化目标

$$\min L(\mathbf{w}) = \sum_{i=1}^N \sum_{j \neq y_i}^N \max(0, (\mathbf{w}_j^T \mathbf{x}_i + b_j) - (\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}))$$

- 计算梯度，对于 $\forall j \neq y_i$


$$\frac{\partial L(\mathbf{w})}{\partial b_j} = \begin{cases} 1, & \text{if } (\mathbf{w}_j^T \mathbf{x}_i + b_j) - (\mathbf{w}_{y_i}^T \mathbf{x}_i + b_{y_i}) > 0 \\ 0, & \text{otherwise} \end{cases}$$

- 梯度下降，对于 $\forall j \neq y_i$

$$\mathbf{w}_j \leftarrow \mathbf{w}_j - \alpha \frac{\partial L(\mathbf{w})}{\partial \mathbf{w}_j} \qquad b_j \leftarrow b_j - \alpha \frac{\partial L(\mathbf{w})}{\partial b_j}$$

感知机的缺点：仅适用于线性可分问题


- 线性可分：逻辑与关系 \rightarrow 只有当所有输入都为真时，输出才为真



x_1	x_2	y
0	0	0
0	1	0
1	0	0
1	1	1

感知机的缺点：仅适用于线性可分问题


- 线性可分：逻辑或关系 \rightarrow 只要其中一个输入为真，输出就为真



x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	1

感知机的缺点：仅适用于线性可分问题

- 非线性可分：逻辑异或关系 \rightarrow 我们无法通过一条直线将 $(0,1)$ 和 $(1,0)$ 分开，同时又保持 $(0,0)$ 和 $(1,1)$ 的分类正确



x_1	x_2	y
0	0	0
0	1	1
1	0	1
1	1	0

Thank You!

